

Vizualizarea datelor din Spark SQL

Postolache Andreea Miruna, grupa 405

Rezumat

Referatul cuprinde patru capitole: Apache Spark, Spark SQL, vizualizarea datelor și partea practică.

Primele două părți prezintă informații de bază, introductive pentru a putea face trecerea spre tema aleasă care are legătură cu Spark SQL. Apache Spark este un motor utilizat pentru procesarea unui volum mare de date, putând fi folosit în limbaje de programare, ca: Java, Scala, Python și R. Acesta are în componență componenta de bază Spark Core și a patru componente: Sparq SQL, Spark Streaming, MLlib și GraphX [1, 3]. Sparq SQL are rolul de a procesa datele structurate, fiind o optimizare a Apache Hive. Sparq SQL are o serie de obiective și caracteristici (integrarea cu Spark, accesarea uniformă a datelor, compatibilitatea cu Hive, conectivitate, performanță și scalabilitate) [4, 5].

Partea de vizualizare a datelor surprinde tipurile de vizualizări, aspecte privind avantajele și dezavantajele vizualizărilor, dar și menționarea de grafice ce trebuie utilizate în funcție de ceea ce se dorește a fi studiat pe setul de date ales.

Ultimul capitol este legat de partea practică în care pentru a ajunge la crearea vizualizărilor a fost nevoie mai întâi de trecerea prin procesul de validare și curățare a datelor. După obținerea setului de date final, s-au realizat vizualizări diverse pentru a înțelege distribuția datelor, a relațiilor dintre variabile, pentru a compara grupuri de valori pentru categorii.

Apache Spark

Apache Spark, potrivit documentației oficiale, este un motor utilizat pentru procesarea unei cantități mari de date [1], fiind un framework open-source care a fost dezvoltat începând cu anul 2009 în cadrul Universității din California Berkeley [2]. Prin accesarea API-ului oferit de Spark, acesta poate fi utilizat în limbaje de programare, precum: Java, Scala, Python și R [1].

În ceea ce privește stiva Spark (Fig 1.) se poate remarca prezența componentei de bază – Spark Core care are rolul de a gestiona memoria, sarcinile și de a interacționa cu sisteme de stocare – și a patru mari componente: Spark SQL – procesarea datelor structurate, Spark Streaming – analize în timp real, MLlib – învățarea automată, GraphX – procesarea graficelor [3]. Mai mult, Apache Spark permite utilizarea API-ului Pandas în Spark care poate folosit, de exemplu, pentru reprezentarea grafică a datelor [1].




Fig 1 – Stiva Spark [3]

Spark SQL

Spark SQL este una dintre componentele Spark menționate mai sus, având rolul procesării datelor structurate. Acesta a fost creat cu scopul de a repara limitările întâlnite la Apache Hive dintre care se pot menționa [4]:

- Performanță redusă în ceea ce privește analiza seturilor de date de dimensiune medii, cauzată de utilizarea MapReduce pentru executarea cererilor ad-hoc.

- Imposibilitatea de reluare a procesării (dacă procesul este întrerupt într-un anumit moment, atunci acesta trebuie luat de la început)
- Erori la execuție cauzate de incapacitatea gestionării bazelor de date criptate în timp ce coșul de gunoi este activat [4]

Un aspect relevant este acela că Spark SQL oferă utilizatorilor posibilitatea să aleagă și să îmbine API-urile relaționale, respectiv procedurale pentru a efectua interogări, analize pe o scară mare de date. De asemenea, Spark SQL, pentru realizarea de operațiuni relaționale pe date externe și colecții distribuie din Spark, oferă un API DataFrame. Mai mult, acesta permite utilizatorilor scrierea regulilor de optimizare prin introducerea optimizatorului Catalyst [5].

Dintre obiectivele setate pentru Spark SQL se remarcă [5]:

- Permite procesării relaționale în cadrul surselor de date externe prin API și în cadrul programelor Spark
- Performează ridicat prin folosirea tehnicilor din SGBD
- Acceptarea de surse noi și diferite de date într-un mod ușor
- Permite extensii algoritmilor analitici avansați

Dintre caracteristicile Spark SQL se regăsesc următoarele [4]:

- Integrarea interogărilor Spark SQL în Spark și permiterea interogării datelor structurate prin SQL sau cu API DataFrame în limbaje de programare, ca: Scala, Java, Python și R,
- Accesul uniform la date, prin permiterea accesării de surse de date variate (Hive, Parquet, JSON, etc) de către SQL și DataFrame,
- Compatibilitatea cu Hive, care poate fi observată în imaginea de mai jos (Fig. 2), indică faptul că Spark SQL poate executa pe datele curente interogări Hive fără a fi necesare modificări,




Fig 2 – Compatibilitatea Hive (<https://spark.apache.org/sql/>)

- Conectivitatea standard este reprezentată prin includerea în Spark SQL a conexiunilor standard ale industriei – JDBC, ODBC – pentru utilitare „business intelligence”.




Fig 3- Conectivitate standard (<https://spark.apache.org/sql/>)

- Performanță și scalabilitate: creșterea performanței interogărilor marcată prin includerea în Spark SQL a unui optimizator, a stocării pe coloane și a generării de cod, un alt aspect fiind posibilitatea scalării la un număr mare de noduri și la interogări ce necesită mai mult timp prin utilizarea motorului Spark [4].

Vizualizarea datelor

În ceea ce privește elaborarea unui proiect în Data Science, o etapă importantă din procesul de dezvoltare este vizualizarea datelor care presupune crearea de reprezentări grafice a datelor prin apelarea la histograme, diverse tipuri de diagrame sub formă de: puncte, linii, bare, cutii, „pie”, „violin”, „scatter plot” [6]. Se poate observa că scopul vizualizării datelor în această manieră este acela de a analiza mai ușor, de a forma o părere mult mai clară asupra setului de date, a relațiilor dintre date. Acestea din urmă reprezintă o parte din avantajele utilizării vizualizării de date, la care se adaugă: studierea mai rapidă a datelor facilitată de folosirea paletelor de culori, a graficelor corespunzătoare pentru observația în cauză, observarea de tipare, accesibilitatea – datele pot fi interpretate și înțelese atât de persoane tehnice, cât și non-tehnice, oferirea posibilității de către unele vizualizări de a interacționa pentru obținerea de mai multe informații [6, 7]. De asemenea, există și o serie de dezavantaje: interpretarea greșită și tragerea de concluzii eronate cu privire la setul de date analizat, complexitatea setului de date care poate duce la crearea unei vizualizări aglomerate, greu de urmărit, întâmpinarea de probleme care să pericliteze confidențialitatea și securitatea datelor (folosirea de seturi de date ce conțin informații care încalcă confidențialitatea, atacurile cibernetice), modul de alegere al datelor care sunt vizualizate, un exemplu în acest sens fiind omiterea din seturile de date a unor informații necesare, utile care duce la realizarea unei vizualizări ce nu va prezenta cu adevărat realitatea datelor [7].

Un rol important în vizualizarea datelor îl are alegerea reprezentării grafice potrivite pentru setul de date ales și a ceea ce se dorește a fi cercetat [8]:

- schimbarea datelor în timp: grafice cu bare, linie



Fig 4 – Grafice cu bare și linie [9, 10]

În ceea ce privește interpretarea graficelor de mai sus, în cazul graficului cu bare, cel care analizează datele urmărește valoarea determinată de înălțimea bării, iar în cazul celui de-al doilea grafic, atenția se focalizează asupra poziției verticale, urmărind în același timp axa timpului.

- reprezentarea informațiilor ca întreg și separat: grafice „pie”, bara suprapusă, grafice de suprafață suprapuse

În cazul graficul „pie” fiecare felie reprezintă procentul pe care îl ocupă fiecare nivel al variabilei categoriale din total, împreună formând un întreg [11], așa cum se poate observa în figura de mai jos.




Fig 5 - Grafic „pie” [11]

În ceea ce privește graficul cu bare suprapuse, fiecare bară este alcătuită dintr-un număr de sub-bare corespunzătoare unui nivel al celei de-a doua variabile categorice. Acest tip de reprezentare se folosește de două variabile categorice și este folosit atât pentru a compara valorile numerice asociate nivelurilor celei de-a doua variabile pe baza înălțimii, dar și pentru a compara ca la nivelul unui întreg.




Fig 6 – Grafic cu bare suprapuse [12]

Graficul de suprafață („area chart”) este o combinație a graficelor de tipul: linie și bare. Pornind de la acestea, graficul de suprafață suprapusă este folosit când se dorește observarea evoluției nu doar a întregului, ci a fiecărui grup în parte. Fiecare grup are marginea inferioară a reprezentării grafice pe partea unde se termină grupul anterior. Comparăția grupurilor privind influența asupra totalului se face pe baza studierii înălțimii segmentelor curbei [13].




Fig 7 – Grafic de suprafață [13]

- modul de distribuire a datelor: grafice cu bare, histograme, cutii, „violin”

Graficele cu bare au fost explicate mai sus.

În ceea ce privește histograma, aceasta este reprezentată sub forma unei succesiuni de bare, semnificând distribuția valorilor variabilei numerice selectate în funcție de mărimea bin-urilor care a fost aleasă astfel încât distribuția datelor să arate bine. Potrivit figurii de mai jos, bin-ul cu mărimea de 1 oferă cea mai realistă distribuție pentru datele curente. [14]




Fig 8 – Histogramă [14]

Un aspect important în interpretare este faptul că înălțimea bin-urilor reprezintă numărul de date care se află în acel fragment de bin. Mai mult, pentru studierea distribuției, histograma oferă informații privind vârfurile distribuției, dacă este o distribuție simetrică (media, mediana au aceeași valoare), înclinată la dreapta – „right skewed” (mediana este mai mică decât media), înclinată la stânga – „left skewed” (mediana este mai mare decât media) sau dacă există puncte de deviație („outliers”) [14].

Graficele cu cutii – „box plots” – sunt reprezentate sub forma unei cutii cu prelungiri în a cărei construcție stau la bază cuartilele setului de date: Q1 – mai mare decât 25% dintre date și mai mică decât 75%, Q2 – mediana și Q3 – mai mare decât 75% dintre date și mai mică decât 25%. De asemenea, aflarea distanței

până la care se întind prelungirile este determinată de aflarea celui mai îndepărtat punct (de la ambele capete ale cutiei) din setul de date aflat la o distanță de 1.5 ori mai mare decât diferența dintre Q3 și Q1 care poartă numele de IQR. Punctele aflate după această limită sunt considerate puncte de deviație („outliers”) [15].




Fig 9 – Elemente specifice unui „box plot” [15]

Acest tip de vizualizare oferă multe informații privind distribuția datelor, dintre care se pot menționa: tipul distribuției (simetrică sau înclinată), poziția cuartilelor și a punctelor aberante. În cazul în care mediana se află în centrul cutiei, atunci distribuția este simetrică, altfel este înclinată [15].




Fig 10 – Distribuția „box plot-urilor”[15]

Un alt tip de grafic folosit pentru studierea distribuirii datelor este „violin plot” care seamănă cu graficul exemplificat mai sus, doar că spre deosebire de acesta folosește curbe de densitate, ale căror lățime este dată de frecvența punctelor de

date din zona respectivă. Mai mult, la „violin plot” se poate adăuga și un grafic tip cutie pentru a oferi informații specifice [16].




Fig 11 – Grafic „violin” [16]

- compararea valorilor în funcție de grupuri de date: grafice cu bare, puncte, bare grupate, „violin”, cutii și linie

Graficele cu bare, unde o bară îi corespunde unui grup și compară valorile grupurilor. În aceeași manieră se realizează și la graficul cu puncte, valoarea fiind determinată de poziția punctului [8].




Fig 12 – Graficul cu puncte [8]

Graficul cu bare grupate este un grafic de bare dar pentru două variabile categoricale și presupune ca pentru fiecare nivel al celei de-a doua variabile categoricale să se construiască o nouă bară care va fi grupată cu restul barelor

până se ajunge la numărul total de nivele al variabilei, acestea fiind colorate diferit pentru o distingere mai bună [17].




Fig 13 – Graficul cu bare grupate [8]

În acest fel datele pot fi comparate în funcție de valorile obținute pe barele care fac parte din același nivel, așa cum se poate observa în figura de mai sus: veniturile din Cherry St. sunt cele mai mari în ceea ce privește hainele, iar veniturile pentru accesorii din Lime Av. sunt mai mari decât cele din Apple Rd.

Graficele de tipul cutie și „violin” sunt de asemenea folosite pentru compararea datelor. În ceea ce privește primul tip de grafice, comparațiile se pot referi la valorile de minim, maxim, la valorile cuantilelor, iar pentru al doilea tip se adaugă și comparații privind vârfurile, văile și cozile curbei de densitate [15, 16].




Fig 14 – Graficele „violin” și cutie [15, 16]

În cazul graficului linie se creează o linie per grup și se compară valorile grupurilor obținute în funcție de timp. [8]




Fig 15 – Graficul linie [17]

- relațiile dintre date: diagrama de dispersie („scatter plot”), heatmap

Diagrama de dispersie („scatter plot”) prezintă corelația dintre două variabile, iar în funcție de modul în care sunt așezate punctele se poate determina tipul relației dintre variabile în funcție de direcție, apropierea punctelor și liniaritate [18].

În cazul în care punctele sunt dispuse pe o direcție ascendentă, valorile crescând împreună, atunci relația dintre variabile este una pozitivă. Dacă direcția ar fi fost descendentă, atunci relația dintre variabile este una negativă [18].

De asemenea, cu cât punctele sunt mai unite, cu atât relația dintre variabile este mai strânsă [18].

În funcție de așezarea punctelor se poate determina dacă relația dintre variabile este una liniară sau nu [18].

Mai mult, prin analiza diagramei de dispersie se pot detecta puncte de deviație („outliers”). În plus, la diagrama de dispersie se pot adăuga variabile suplimentare prin culori, forme, mărimea punctelor [18].




Fig 16 – Distribuția „scatter plot”[18]

Heatmap este un grafic pentru două variabile alese, valorile fiind exprimate prin pătrate colorate, fiecare nuanță corespunzând unei valori. Relația dintre variabile poate fi distinsă prin observarea existenței unor tipare în colorarea celulelor [19].




Fig 17 – „Heatmap” [19]

Mai mult, un tip de heatmap este „correlogram” care în locul celor două variabile conține o listă de variabile numerice, urmărindu-se aflarea relației dintre ele: cu cât valoarea este mai mare, cu atât cele două variabile sunt pozitiv corelate. În exemplul din figura de mai jos se observă o corelare puternică, pozitivă între lungimea și lățimea petalelor, iar între lungimea și lățimea sepalelor este o corelare negativă [19].




Fig 18 – Correlogram [19]

- datele geografice: hartă de tipul „choropleth” sau cartograme

Harta de tipul „choropleth” este ca o hartă termică, colorarea fiind făcută pe regiuni geografice. Analiza acestui tip de vizualizări se face în funcție de colorare, care este asociată unei valori pentru variabila aleasă spre analiză. Astfel, se pot compara regiunile prin compararea valorilor asociate colorării [19].




Fig 19 - Choropleth [19]

Cartograma este o hartă care, în funcție de o variabilă numerică aleasă, distorsionează regiunile și le colorează corespunzător, așa cum poate fi observat în figura de mai jos [8].




Fig 20 - Cartogramă [8]

Astfel, vizualizările datelor reprezintă o etapă importantă în analiza datelor, în înțelegerea mai avansată a variabilelor, a legăturilor dintre ele, a distribuției valorilor.

Partea practică

<https://colab.research.google.com/drive/1FZhXiIjA2-Q8x3hkXxWx9OFK5ASwOdME?usp=sharing>

Bibliografie

1. <https://spark.apache.org/docs/3.5.1/>
2. <https://www.databricks.com/spark/about>
3. <https://aws.amazon.com/what-is/apache-spark/>
4. <https://thirdeyeddata.ai/spark-sql/>
5. <https://opensource.com/article/19/3/sql-scale-apache-spark-sql-and-dataframes>
6. <https://www.tableau.com/learn/articles/data-visualization#definition>
7. <https://www.techtarget.com/searchbusinessanalytics/definition/data-visualization>
8. <https://www.atlassian.com/data/charts/how-to-choose-data-visualization>
9. https://help.salesforce.com/s/articleView?id=sf.bi_chart_intro_time_bar.htm&type=5
10. <https://www.timescale.com/blog/what-is-a-time-series-plot-and-how-can-you-create-one/>
11. <https://www.atlassian.com/data/charts/pie-chart-complete-guide>
12. <https://www.atlassian.com/data/charts/stacked-bar-chart-complete-guide>
13. <https://www.atlassian.com/data/charts/area-chart-complete-guide>
14. <https://www.atlassian.com/data/charts/histogram-complete-guide>
15. <https://www.atlassian.com/data/charts/box-plot-complete-guide>
16. <https://www.atlassian.com/data/charts/violin-plot-complete-guide>
17. <https://www.atlassian.com/data/charts/line-chart-complete-guide>
18. <https://www.atlassian.com/data/charts/what-is-a-scatter-plot>
19. <https://www.atlassian.com/data/charts/heatmap-complete-guide>